

[Universidad] – Base de Datos III – Proyecto: Implementación de un Data Warehouse

Primera Presentación (puntos 1 a 5): Data Warehouse del Campeonato Mundial de Fórmula 1

Integrantes: Jhonatan Moisés Villca, [Integrante 2], [Integrante 3] – Docente: Rodnie Montaña Aguilera

1. Tema del Proyecto

Tema: análisis del rendimiento competitivo de pilotos, escuderías y circuitos en el Campeonato Mundial de Fórmula 1 (1950–2024). **Conjunto de datos:** «Formula 1 World Championship (1950–2024)» de Kaggle (Rohan Rao, datos de Ergast API): 14 archivos CSV relacionados por claves con $\approx 1\,125$ carreras, $\approx 26\,700$ resultados, ≈ 860 pilotos, ≈ 210 escuderías, 77 circuitos, 139 estados de finalización, posiciones del campeonato, clasificación, vueltas ($\approx 589\,000$) y paradas en boxes.

Suficiencia de los datos: contiene eventos medibles para la tabla de hechos (posición, puntos, vueltas y tiempos de cada resultado), entidades descriptivas con jerarquías para las dimensiones (piloto, escudería, circuito $\rightarrow$ país, fecha $\rightarrow$ temporada $\rightarrow$ década) y 75 años de historia. Además requiere limpieza (nulos escritos como «\N», tiempos en texto, varios sistemas de puntos), lo que justifica el proceso ETL.

Contexto y necesidad de análisis: cada temporada tiene Grandes Premios en distintos circuitos; los pilotos corren para una escudería y suman puntos según su posición final. Los datos están normalizados para registrar resultados, no para analizarlos en el tiempo. La necesidad es **evaluar de forma comparable entre épocas quién gana, con qué frecuencia y con qué confiabilidad**, para equipos, analistas, medios y patrocinadores. No es un tema de ventas, inventario ni similares: combina métricas ordinales, aditivas y semiaditivas, cambios de reglamento y varios procesos de negocio.

2. Objetivos del Data Warehouse

Objetivo general: implementar un Data Warehouse con un DataMart de Rendimiento en Carrera que integre los resultados históricos de la Fórmula 1 para analizar el rendimiento de pilotos, escuderías y circuitos mediante indicadores, consultas, cubos OLAP, reportes y cuadros de mando.

Objetivos específicos (medibles con el indicador indicado):

Cód.	Objetivo específico	Indicador
OE1	Medir la conversión de la pole en victoria por temporada y circuito.	% victorias desde la pole
OE2	Determinar el dominio de las escuderías por temporada y década.	% de victorias y cuota de puntos
OE3	Cuantificar la confiabilidad de las escuderías y las causas de abandono.	Tasa de abandono
OE4	Comparar pilotos de distintas épocas con puntos normalizados.	Puntos por carrera (sistema actual)
OE5	Caracterizar los circuitos por adelantamientos y abandonos.	Prom. de posiciones ganadas
OE6	Evaluar la evolución del ritmo por circuito desde 2004.	Velocidad media de vuelta rápida

Estos objetivos definen el hecho (resultado de carrera), las dimensiones (tiempo, carrera, circuito, piloto, escudería y estado), las métricas, la granularidad y los reportes y cuadros de mando de la segunda presentación.

3. Modelado Conceptual del DataMart

Tres DataMarts posibles:

- **DM1 Rendimiento en Carrera:** proceso resultado de carrera; cobertura completa 1950–2024.
- **DM2 Estrategia en Pista:** vueltas y paradas en boxes; solo desde 1996 y 2011.
- **DM3 Clasificación y Campeonato:** sesiones de clasificación y posiciones del campeonato.

DataMart seleccionado: DM1, porque el resultado de carrera es el proceso central (de él salen los puntos y los campeonatos), tiene la historia completa, responde los seis objetivos y sus dimensiones se reutilizan en DM2 y DM3.

Modelo conceptual: proceso de negocio «disputa de un Gran Premio»; hecho **Resultado de carrera**; dimensiones con sus jerarquías: Tiempo (década → año → mes → fecha), Carrera (temporada → Gran Premio), Circuito (continente → país → circuito), Piloto (nacionalidad → piloto), Escudería (nacionalidad → escudería) y Estado (categoría → estado).

Granularidad: cada registro de la tabla de hechos es **el resultado de un piloto, con un auto de una escudería, en un Gran Premio** (una fila de results.csv); ≈ 26 700 registros.

4. Modelado Lógico del DataMart

Esquema en estrella. Cada dimensión se relaciona 1:N con la tabla de hechos mediante su clave sustituta (PK) y la clave foránea (FK) correspondiente:

Tabla	Atributos
fact_resultado_carrera	PK sk_resultado; FK sk_tiempo, sk_carrera, sk_circuito, sk_piloto, sk_escuderia, sk_estado; id_resultado_origen, codigo_posicion; métricas: puntos, puntos_sistema_actual, posicion_salida, posicion_final, posiciones_ganadas, vueltas_completadas, tiempo_vuelta_rapida_ms, velocidad_vuelta_rapida_kmh, edad_piloto, puntos_acumulados_temporada; indicadores 0/1: es_victoria, es_podio, es_pole, es_abandono, es_finalizado
dim_tiempo	PK sk_tiempo (AAAAMMDD); fecha, mes, trimestre, anio, decada
dim_carrera	PK sk_carrera; id_carrera_origen, temporada, ronda, nombre_gran_premio, sistema_puntos
dim_circuito	PK sk_circuito; id_circuito_origen, nombre_circuito, localidad, pais, continente
dim_piloto	PK sk_piloto; id_piloto_origen, nombre_completo, fecha_nacimiento, nacionalidad
dim_escuderia	PK sk_escuderia; id_escuderia_origen, nombre_escuderia, nacionalidad
dim_estado	PK sk_estado; id_estado_origen, descripcion_estado, categoria_estado

- **Claves:** las claves sustitutas (sk_*) son enteros generados por el DBMS; las claves naturales del dataset (id_*_origen) son únicas y el ETL las usa para buscar la clave sustituta.
- **Métricas aditivas:** puntos, vueltas, posiciones ganadas e indicadores 0/1 (su suma cuenta victorias, podios o abandonos).
- **Métrica semiaditiva:** puntos acumulados de la temporada; se suma entre pilotos de una ronda, pero en el tiempo se toma el último valor.
- **Métricas no aditivas:** posiciones, tiempos, velocidad, edad y porcentajes.

Verificación: OE1 usa es_pole y es_victoria por carrera y circuito; OE2, es_victoria y puntos por escudería y década; OE3, es_abandono por escudería y estado; OE4, puntos_sistema_actual por piloto; OE5, posiciones_ganadas por circuito; OE6, la vuelta rápida por circuito y temporada. Todos los objetivos se pueden responder con el modelo.

5. Modelado Físico del DataMart

Se implementó en **PostgreSQL 16** (base dw_formula1, esquema dw_f1) con scripts SQL que crean las seis dimensiones y la tabla de hechos, los índices y la dimensión Tiempo (1950–2030).

- **Tipos de datos:** claves INTEGER/BIGINT IDENTITY; posiciones e indicadores SMALLINT; puntos NUMERIC(5,2) para admitir medios puntos; tiempos en milisegundos; fechas DATE.
- **Restricciones e integridad referencial:** PK en todas las tablas, UNIQUE en las claves naturales, seis FK obligatorias desde los hechos y reglas CHECK (posiciones > 0, puntos ≥ 0, es_victoria = 1 solo si posicion_final = 1). Se probó que el DBMS rechaza hechos con dimensiones inexistentes, resultados duplicados y el borrado de dimensiones con hechos.
- **Índices y orientación al análisis y al ETL:** índices en cada FK, en (piloto, tiempo), (escudería, tiempo) y en los atributos de las jerarquías; la clave natural única permite recargar sin duplicar y el miembro «Desconocido» (-1) evita perder hechos en la carga.