

[Universidad] – Base de Datos III – Proyecto: Implementación de un Data Warehouse

Primera Presentación (puntos 1 a 5): Data Warehouse de puntualidad de vuelos en EE. UU. (2015)

Integrantes: Jhonatan Moisés Villca, [Integrante 2], [Integrante 3] – Docente: Rodnie Montaña Aguilera

1. Tema del Proyecto

Tema: análisis de la puntualidad, los retrasos y las cancelaciones de los vuelos comerciales nacionales de Estados Unidos en 2015. **Conjunto de datos:** «2015 Flight Delays and Cancellations» de Kaggle, publicado por el Departamento de Transporte de EE. UU. con datos de la Oficina de Estadísticas de Transporte (BTS). Tiene tres archivos CSV: flights.csv (≈ 5,8 millones de vuelos con fecha, aerolínea, número de vuelo, aeropuertos de origen y destino, horarios programados y reales, retrasos, tiempos de rodaje y de vuelo, distancia, cancelación, desvío y minutos de retraso por causa), airlines.csv (14 aerolíneas) y airports.csv (322 aeropuertos con ciudad, estado y coordenadas).

Suficiencia de los datos: cada vuelo es un evento medible con métricas numéricas (minutos de retraso, tiempos, distancia) y con descriptores que forman dimensiones con jerarquías: fecha → mes → trimestre, hora → franja horaria y aeropuerto → ciudad → estado → región. El volumen y los problemas de calidad (horas en formato hhmm, valores vacíos en vuelos cancelados o desviados, aeropuertos con códigos numéricos en lugar del código IATA en octubre) justifican un Data Warehouse y un proceso ETL.

Contexto y necesidad de análisis: según la BTS, un vuelo está retrasado si llega 15 minutos o más después de lo programado, y las aerolíneas informan la causa (la propia aerolínea, el clima, el sistema aéreo nacional, la seguridad o la llegada tardía del avión). Los datos están en un solo archivo plano, útil para registrar vuelos pero no para analizarlos. La necesidad es **saber dónde, cuándo y por qué se producen los retrasos y las cancelaciones** (por aerolínea, aeropuerto, ruta, horario y causa), para que aerolíneas, aeropuertos y pasajeros tomen mejores decisiones. No es un tema de ventas ni de inventario: es el análisis del desempeño operativo de un sistema de transporte.

2. Objetivos del Data Warehouse

Objetivo general: implementar un Data Warehouse con un DataMart de Puntualidad de Vuelos que integre los vuelos de 2015 para analizar la puntualidad, los retrasos y las cancelaciones por aerolínea, aeropuerto, ruta y período, mediante indicadores, consultas, cubos OLAP, reportes y cuadros de mando.

Objetivos específicos (medibles con el indicador indicado):

Cód.	Objetivo específico	Indicador
OE1	Medir la puntualidad de cada aerolínea por mes.	% de vuelos puntuales
OE2	Cuantificar las cancelaciones y los desvíos por aerolínea y motivo.	% de cancelación y de desvío
OE3	Identificar qué causas generan más minutos de retraso.	% de minutos por causa
OE4	Determinar los aeropuertos y rutas con mayor retraso.	Retraso promedio de llegada

OE5	Analizar los retrasos según la franja horaria y el día de la semana.	Retraso promedio de salida
OE6	Evaluar la eficiencia en tierra de cada aeropuerto.	Tiempo promedio de rodaje

Estos objetivos definen el hecho (vuelo), las dimensiones (fecha, hora, aerolínea, aeropuerto y motivo de cancelación), las métricas, la granularidad y los reportes y cuadros de mando de la segunda presentación.

3. Modelado Conceptual del DataMart

Tres DataMarts posibles:

- **DM1 Puntualidad de Vuelos:** cada vuelo con sus retrasos, cancelación y desvío.
- **DM2 Causas de Retraso:** minutos de retraso de cada vuelo repartidos por causa.
- **DM3 Operaciones Aeroportuarias:** resumen diario de salidas, llegadas y cancelaciones de cada aeropuerto.

DataMart seleccionado: DM1, porque tiene el detalle de cada vuelo (los otros dos se pueden obtener de él), responde los seis objetivos y sus dimensiones se reutilizan en DM2 y DM3.

Modelo conceptual: proceso de negocio «operación de un vuelo programado»; hecho **Vuelo**; dimensiones con sus jerarquías: Fecha (año → trimestre → mes → fecha, y día de la semana), Hora de salida (franja horaria → hora), Aerolínea, Aeropuerto (región → estado → ciudad → aeropuerto), que se usa dos veces, como origen y como destino, y Motivo de cancelación.

Granularidad: cada registro de la tabla de hechos es **un vuelo programado de una aerolínea en una fecha** (una fila de flights.csv), identificado por la fecha, la aerolínea, el número de vuelo, el aeropuerto de origen y la hora programada de salida; ≈ 5,8 millones de registros.

4. Modelado Lógico del DataMart

Esquema en estrella. Cada dimensión se relaciona 1:N con la tabla de hechos mediante su clave sustituta (PK) y la clave foránea (FK) correspondiente:

Tabla	Atributos
fact_vuelo	PK sk_vuelo; FK sk_fecha, sk_hora_salida, sk_aerolinea, sk_aeropuerto_origen, sk_aeropuerto_destino, sk_motivo_cancelacion; numero_vuelo, matricula_avion, salida_programada; métricas en minutos: retraso_salida_min, retraso_llegada_min, taxi_salida_min, taxi_llegada_min, tiempo_aire_min, retraso por causa (aerolínea, clima, sistema aéreo, seguridad, avión tardío); distancia_millas; indicadores 0/1: es_cancelado, es_desviado, es_retrasado, es_puntual
dim_fecha	PK sk_fecha (AAAAMMDD); fecha, dia_semana, es_fin_de_semana, mes, trimestre, anio
dim_hora	PK sk_hora (0 a 23); hora_texto, franja_horaria
dim_aerolinea	PK sk_aerolinea; codigo_iata, nombre_aerolinea
dim_aeropuerto	PK sk_aeropuerto; codigo_iata, nombre_aeropuerto, ciudad, estado, region, latitud, longitud

dim_motivo_cancelacion	PK sk_motivo_cancelacion; codigo_motivo (N, A, B, C, D), descripcion
------------------------	--

- **Claves:** las claves sustitutas (sk_*) son enteros generados por el DBMS; los códigos IATA del dataset son claves naturales únicas que el ETL usa para buscar la clave sustituta. dim_aeropuerto se relaciona dos veces con los hechos (origen y destino).
- **Métricas aditivas:** minutos de retraso (total y por causa), tiempos, distancia e indicadores 0/1 (su suma cuenta vuelos cancelados, retrasados o puntuales).
- **Métricas semiaditivas:** no hay en este hecho, porque cada vuelo es un evento independiente y no un saldo acumulado.
- **Métricas no aditivas:** porcentajes de puntualidad y de cancelación, y promedios; se recalculan desde sus componentes.

Verificación: OE1 usa es_puntual por aerolínea y mes; OE2, es_cancelado y es_desviado por aerolínea y motivo; OE3, los minutos por causa; OE4, retraso_llegada_min por aeropuertos de origen y destino; OE5, retraso_salida_min por franja horaria y día; OE6, taxi_salida_min por aeropuerto de origen. Todos los objetivos se pueden responder con el modelo.

5. Modelado Físico del DataMart

Se implementó en **PostgreSQL 16** (base y esquema dw_vuelos) con scripts SQL que crean las cinco dimensiones y la tabla de hechos, los índices y los datos fijos (fechas 2014–2016, las 24 horas y los motivos de cancelación).

- **Tipos de datos:** claves INTEGER/BIGINT IDENTITY; minutos y distancia SMALLINT (los retrasos negativos indican adelanto); indicadores SMALLINT; fecha DATE y hora programada TIME; códigos VARCHAR(3).
- **Restricciones e integridad referencial:** PK en todas las tablas, UNIQUE en los códigos IATA y en la clave natural del vuelo, seis FK obligatorias (dos hacia dim_aeropuerto) y reglas CHECK (distancia > 0, un vuelo cancelado debe tener motivo, es_retrasado = 1 solo si llegó con 15 minutos o más de retraso). Se probó que el DBMS rechaza aerolíneas inexistentes, vuelos duplicados y el borrado de aeropuertos con vuelos.
- **Índices y orientación al análisis y al ETL:** índices en cada FK, en (aerolínea, fecha), en la ruta (origen, destino) y un índice parcial de vuelos cancelados; la clave natural única permite recargar sin duplicar y el miembro «Desconocido» (-1) evita perder vuelos con códigos no encontrados.