

[Universidad] – Base de Datos III – Proyecto: Implementación de un Data Warehouse

Primera Presentación (puntos 1 a 5): Data Warehouse de puntualidad de vuelos en EE. UU. (2015)

Integrantes: Jhonatan Moisés Villca, [Integrante 2], [Integrante 3] – Docente: Rodnie Montaña Aguilera

1. Tema del Proyecto

Tema: análisis de la puntualidad, los retrasos y las cancelaciones de los vuelos comerciales nacionales de Estados Unidos en 2015. **Conjunto de datos:** «2015 Flight Delays and Cancellations» de Kaggle, publicado por el Departamento de Transporte de EE. UU. con datos de la Oficina de Estadísticas de Transporte (BTS). Tiene tres archivos CSV: flights.csv (≈ 5,8 millones de vuelos con fecha, aerolínea, número de vuelo, aeropuertos de origen y destino, horarios programados y reales, retrasos, tiempos de rodaje y de vuelo, distancia, cancelación, desvío y minutos de retraso por causa), airlines.csv (14 aerolíneas) y airports.csv (322 aeropuertos con ciudad, estado y coordenadas).

Enlace del conjunto de datos: <https://www.kaggle.com/datasets/usdot/flight-delays>

Suficiencia de los datos: cada vuelo es un evento medible con métricas numéricas (minutos de retraso, tiempos, distancia) y con descriptores que forman dimensiones con jerarquías: año → trimestre → mes → fecha, franja horaria → hora y región → estado → ciudad → aeropuerto. El volumen y los problemas de calidad (horas en formato hhmm, valores vacíos en vuelos cancelados o desviados, aeropuertos con códigos numéricos en lugar del código IATA en octubre) justifican un Data Warehouse y un proceso ETL.

Contexto y necesidad de análisis: según la BTS, un vuelo está retrasado si llega 15 minutos o más después de lo programado, y las aerolíneas informan la causa (la propia aerolínea, el clima, el sistema aéreo nacional, la seguridad o la llegada tardía del avión). Los vuelos están en un único archivo plano (flights.csv), útil para registrarlos pero no para analizarlos. La necesidad es **saber dónde, cuándo y por qué se producen los retrasos y las cancelaciones** (por aerolínea, aeropuerto, ruta, horario y causa), para que aerolíneas, aeropuertos y pasajeros tomen mejores decisiones. No es un tema de ventas ni de inventario: es el análisis del desempeño operativo de un sistema de transporte.

2. Objetivos del Data Warehouse

Objetivo general: implementar un Data Warehouse con un DataMart de Puntualidad de Vuelos que integre los vuelos de 2015 para analizar la puntualidad, los retrasos y las cancelaciones por aerolínea, aeropuerto, ruta y período, mediante indicadores, consultas, cubos OLAP, reportes y cuadros de mando.

Objetivos específicos (cada uno se mide con el indicador indicado y se responde con una consulta SQL):

Cód.	Objetivo específico	Indicador (cómo se mide)
OE1	Medir la puntualidad de cada aerolínea por mes.	% puntuales = vuelos con menos de 15 min de retraso / vuelos completados
OE2	Cuantificar las cancelaciones y los desvíos por aerolínea y motivo.	% cancelados y % desviados sobre los vuelos programados

OE3	Identificar qué causas generan más minutos de retraso.	% de los minutos de retraso de cada causa
OE4	Determinar los aeropuertos y rutas con mayor retraso.	Promedio de minutos de retraso de llegada por ruta
OE5	Analizar los retrasos según la franja horaria y el día de la semana.	Promedio de minutos de retraso de salida por franja y día
OE6	Evaluar la eficiencia en tierra de cada aeropuerto.	Promedio de minutos de rodaje antes del despegue

Estos objetivos son la base del diseño: definen el hecho (vuelo) y su granularidad (un vuelo), las dimensiones (fecha, hora, aerolínea, aeropuerto y motivo de cancelación) y las métricas (minutos de retraso, tiempos, distancia e indicadores). En la segunda presentación cada objetivo tendrá su reporte (puntualidad por aerolínea, cancelaciones por motivo, causas de retraso, rutas y aeropuertos con más retraso, y retrasos por horario) y los indicadores se reunirán en un cuadro de mando de puntualidad con filtros por aerolínea, aeropuerto y mes.

3. Modelado Conceptual del DataMart

Tres DataMarts posibles:

- **DM1 Puntualidad de Vuelos:** cada vuelo con sus retrasos, cancelación y desvío.
- **DM2 Causas de Retraso:** minutos de retraso de cada vuelo repartidos por causa.
- **DM3 Operaciones Aeroportuarias:** resumen diario de salidas, llegadas y cancelaciones de cada aeropuerto.

DataMart seleccionado: **DM1**, porque tiene el detalle de cada vuelo (los otros dos se pueden obtener de él), responde los seis objetivos y sus dimensiones se reutilizan en DM2 y DM3.

Modelo conceptual: proceso de negocio «operación de un vuelo programado»; hecho **Vuelo**; dimensiones con sus jerarquías: Fecha (año → trimestre → mes → fecha, y día de la semana), Hora de salida (franja horaria → hora), Aerolínea, Aeropuerto (región → estado → ciudad → aeropuerto), que se usa dos veces, como origen y como destino, y Motivo de cancelación (Figura 1).

Granularidad: cada registro de la tabla de hechos es **un vuelo programado de una aerolínea en una fecha** (una fila de flights.csv), identificado por la fecha, la aerolínea, el número de vuelo, el aeropuerto de origen y la hora programada de salida; ≈ 5,8 millones de registros.



Figura 1. Modelo conceptual del DataMart Puntualidad de Vuelos: hecho, dimensiones y jerarquías.

4. Modelado Lógico del DataMart

Esquema en estrella (Figura 2). Cada dimensión se relaciona 1:N con la tabla de hechos mediante su clave sustituta (PK) y la clave foránea (FK) correspondiente:

Tabla	Atributos
fact_vuelo	PK sk_vuelo; FK sk_fecha, sk_hora_salida, sk_aerolinea, sk_aeropuerto_origen, sk_aeropuerto_destino, sk_motivo_cancelacion; dimensiones degeneradas: numero_vuelo, matricula_avion, salida_programada; métricas en minutos: retraso_salida_min, retraso_llegada_min, taxi_salida_min, taxi_llegada_min, tiempo_programado_min, tiempo_real_min, tiempo_aire_min, retraso_aerolinea_min, retraso_clima_min, retraso_sistema_aereo_min, retraso_seguridad_min, retraso_avion_tardio_min; distancia_millas; indicadores 0/1: es_cancelado, es_desviado, es_retrasado, es_puntual; fecha_carga (auditoría)
dim_fecha	PK sk_fecha (AAAAMMDD); fecha, dia, dia_semana, nombre_dia, es_fin_de_semana, mes, nombre_mes, trimestre, anio
dim_hora	PK sk_hora (0 a 23); hora_texto, franja_horaria
dim_aerolinea	PK sk_aerolinea; codigo_iata, nombre_aerolinea
dim_aeropuerto	PK sk_aeropuerto; codigo_iata, nombre_aeropuerto, ciudad, estado, region, pais, latitud, longitud

dim_motivo_cancelacion	PK sk_motivo_cancelacion; codigo_motivo (N, A, B, C, D), descripcion
------------------------	--

Estructura del dataset y su uso en el DataMart: cada columna de los archivos CSV se carga en una dimensión, una métrica o un indicador de la tabla de hechos:

Columna del dataset	Significado	En el DataMart (uso)
YEAR MONTH DAY DAY_OF_WEEK	Fecha del vuelo y día de la semana	dim_fecha (dimensión)
AIRLINE	Código de la aerolínea	dim_aerolinea (dimensión)
ORIGIN_AIRPORT DESTINATION_AIRPORT	Aeropuertos de origen y destino	dim_aeropuerto, en dos roles (dimensión)
SCHEDULED_DEPARTURE	Hora programada de salida (hhmm)	salida_programada (degenerada) dim_hora (dimensión)
CANCELLATION_REASON	Motivo: A, B, C o D	dim_motivo_cancelacion (dimensión)
FLIGHT_NUMBER TAIL_NUMBER	Número de vuelo y matrícula del avión	numero_vuelo matricula_avion (dimensiones degeneradas)
DEPARTURE_DELAY	Minutos de retraso en la salida	retraso_salida_min (métrica aditiva)
ARRIVAL_DELAY	Minutos de retraso en la llegada	retraso_llegada_min (métrica aditiva) es_retrasado, es_puntual (indicadores)
TAXI_OUT TAXI_IN	Minutos de rodaje antes del despegue y después del aterrizaje	taxi_salida_min taxi_llegada_min (métricas aditivas)
SCHEDULED_TIME ELAPSED_TIME AIR_TIME	Duración programada, real y en el aire	tiempo_programado_min tiempo_real_min tiempo_aire_min (métricas aditivas)
DISTANCE	Distancia en millas	distancia_millas (métrica aditiva)
AIRLINE_DELAY WEATHER_DELAY AIR_SYSTEM_DELAY SECURITY_DELAY LATE_AIRCRAFT_DELAY	Minutos de retraso por causa: aerolínea, clima, sistema aéreo, seguridad y avión tardío	retraso_aerolinea_min retraso_clima_min retraso_sistema_aereo_min retraso_seguridad_min retraso_avion_tardio_min (métricas aditivas)
CANCELLED DIVERTED	1 si el vuelo fue cancelado o desviado	es_cancelado es_desviado (indicadores 0/1)

DEPARTURE_TIME WHEELS_OFF WHEELS_ON SCHEDULED_ARRIVAL ARRIVAL_TIME	Horas reales y programadas de cada etapa del vuelo	No se cargan: lo necesario ya está en los retrasos y los tiempos
airlines.csv: IATA_CODE, AIRLINE	Código y nombre de la aerolínea	dim_aerolinea (dimensión)
airports.csv: IATA_CODE, AIRPORT, CITY, STATE, COUNTRY, LATITUDE, LONGITUDE	Datos de cada aeropuerto	dim_aeropuerto; la región se deriva del estado (dimensión)

- **Claves:** las claves sustitutas (sk_*) son enteros generados por el DBMS; los códigos IATA del dataset son claves naturales únicas que el ETL usa para buscar la clave sustituta. dim_aeropuerto se relaciona dos veces con los hechos (origen y destino).
- **Métricas aditivas:** minutos de retraso (total y por causa), tiempos, distancia e indicadores 0/1 (su suma cuenta vuelos cancelados, retrasados o puntuales).
- **Métricas semiaditivas:** no hay en este hecho, porque cada vuelo es un evento independiente y no un saldo acumulado.
- **Métricas no aditivas:** porcentajes de puntualidad y de cancelación, y promedios; se recalculan desde sus componentes.

Verificación: OE1 usa es_puntual por aerolínea y mes; OE2, es_cancelado y es_desviado por aerolínea y motivo; OE3, los minutos por causa; OE4, retraso_llegada_min por aeropuertos de origen y destino; OE5, retraso_salida_min por franja horaria y día; OE6, taxi_salida_min por aeropuerto de origen. Todos los objetivos se pueden responder con el modelo.




Figura 2. Modelo lógico del DataMart Puntualidad de Vuelos (esquema en estrella).

PK = clave primaria (sustituta); FK = clave foránea, con la tabla a la que apunta; NK = clave natural única; DD = dimensión degenerada; ||—< = relación 1:N. dim_aeropuerto se relaciona dos veces con fact_vuelo (origen y destino).

5. Modelado Físico del DataMart

Se implementó en **PostgreSQL 16** (base y esquema dw_vuelos) con scripts SQL que crean las cinco dimensiones y la tabla de hechos, los índices y los datos fijos (fechas 2014–2016, las 24 horas y los motivos de cancelación).

- **Tipos de datos:** claves INTEGER/BIGINT IDENTITY; minutos y distancia SMALLINT (los retrasos negativos indican adelanto); indicadores SMALLINT; fecha DATE y hora programada TIME; códigos VARCHAR(3).
- **Restricciones e integridad referencial:** PK en todas las tablas, UNIQUE en los códigos IATA y en la clave natural del vuelo, seis FK obligatorias (dos hacia dim_aeropuerto) y reglas CHECK (distancia > 0, un vuelo cancelado debe tener motivo, es_retrasado = 1 solo si llegó con 15 minutos o más de retraso). Se probó que el DBMS rechaza aerolíneas inexistentes, vuelos cancelados sin motivo, vuelos duplicados, distancias negativas y el borrado de aeropuertos con vuelos.
- **Índices y orientación al análisis y al ETL:** índices en cada FK, en (aerolínea, fecha), en la ruta (origen, destino) y un índice parcial de vuelos cancelados; la clave natural única permite recargar sin duplicar y el miembro «Desconocido» (-1) evita perder vuelos con códigos no encontrados.

La Figura 3 muestra el modelo físico implementado, obtenido del catálogo de PostgreSQL: cada tabla con sus columnas, tipos de datos, claves y columnas obligatorias. Los scripts SQL de creación se entregan junto con el proyecto.




Figura 3. Modelo físico del DataMart Puntualidad de Vuelos en PostgreSQL 16 (esquema dw_vuelos).

PK = clave primaria; FK = clave foránea; UK = forma parte de una restricción UNIQUE; NN = NOT NULL; IDENTITY = valor generado por el DBMS; ||—< = relación 1:N. dim_aeropuerto se relaciona dos veces con fact_vuelo (origen y destino).