

[Universidad] – Base de Datos III – Proyecto: Implementación de un Data Warehouse

Primera Presentación (puntos 1 a 5): Data Warehouse de puntualidad de vuelos en EE. UU. (2015)

Integrantes: Jhonatan Moisés Villca, [Integrante 2], [Integrante 3] – Docente: Rodnie Montaña Aguilera

1. Tema del Proyecto

Tema: análisis de la puntualidad, los retrasos y las cancelaciones de los vuelos comerciales nacionales de Estados Unidos en 2015. **Conjunto de datos:** «2015 Flight Delays and Cancellations» de Kaggle, publicado por el Departamento de Transporte de EE. UU. con datos de la Oficina de Estadísticas de Transporte (BTS). Tiene tres archivos CSV: flights.csv (≈ 5,8 millones de vuelos con fecha, aerolínea, número de vuelo, aeropuertos de origen y destino, horarios programados y reales, retrasos, tiempos de rodaje y de vuelo, distancia, cancelación, desvío y minutos de retraso por causa), airlines.csv (14 aerolíneas) y airports.csv (322 aeropuertos con ciudad, estado y coordenadas).

Suficiencia de los datos: cada vuelo es un evento medible con métricas numéricas (minutos de retraso, tiempos, distancia) y con descriptores que forman dimensiones con jerarquías: año → trimestre → mes → fecha, franja horaria → hora y región → estado → ciudad → aeropuerto. El volumen y los problemas de calidad (horas en formato hhmm, valores vacíos en vuelos cancelados o desviados, aeropuertos con códigos numéricos en lugar del código IATA en octubre) justifican un Data Warehouse y un proceso ETL.

Contexto y necesidad de análisis: según la BTS, un vuelo está retrasado si llega 15 minutos o más después de lo programado, y las aerolíneas informan la causa (la propia aerolínea, el clima, el sistema aéreo nacional, la seguridad o la llegada tardía del avión). Los vuelos están en un único archivo plano (flights.csv), útil para registrarlos pero no para analizarlos. La necesidad es **saber dónde, cuándo y por qué se producen los retrasos y las cancelaciones** (por aerolínea, aeropuerto, ruta, horario y causa), para que aerolíneas, aeropuertos y pasajeros tomen mejores decisiones. No es un tema de ventas ni de inventario: es el análisis del desempeño operativo de un sistema de transporte.

2. Objetivos del Data Warehouse

Objetivo general: implementar un Data Warehouse con un DataMart de Puntualidad de Vuelos que integre los vuelos de 2015 para analizar la puntualidad, los retrasos y las cancelaciones por aerolínea, aeropuerto, ruta y período, mediante indicadores, consultas, cubos OLAP, reportes y cuadros de mando.

Objetivos específicos (cada uno se mide con el indicador indicado y se responde con una consulta SQL):

Cód.	Objetivo específico	Indicador (cómo se mide)
OE1	Medir la puntualidad de cada aerolínea por mes.	% puntuales = vuelos con menos de 15 min de retraso / vuelos completados
OE2	Cuantificar las cancelaciones y los desvíos por aerolínea y motivo.	% cancelados y % desviados sobre los vuelos programados
OE3	Identificar qué causas generan más minutos de retraso.	% de los minutos de retraso de cada causa

OE4	Determinar los aeropuertos y rutas con mayor retraso.	Promedio de minutos de retraso de llegada por ruta
OE5	Analizar los retrasos según la franja horaria y el día de la semana.	Promedio de minutos de retraso de salida por franja y día
OE6	Evaluar la eficiencia en tierra de cada aeropuerto.	Promedio de minutos de rodaje antes del despegue

Estos objetivos son la base del diseño: definen el hecho (vuelo) y su granularidad (un vuelo), las dimensiones (fecha, hora, aerolínea, aeropuerto y motivo de cancelación) y las métricas (minutos de retraso, tiempos, distancia e indicadores). En la segunda presentación cada objetivo tendrá su reporte (puntualidad por aerolínea, cancelaciones por motivo, causas de retraso, rutas y aeropuertos con más retraso, y retrasos por horario) y los indicadores se reunirán en un cuadro de mando de puntualidad con filtros por aerolínea, aeropuerto y mes.

3. Modelado Conceptual del DataMart

Tres DataMarts posibles:

- **DM1 Puntualidad de Vuelos:** cada vuelo con sus retrasos, cancelación y desvío.
- **DM2 Causas de Retraso:** minutos de retraso de cada vuelo repartidos por causa.
- **DM3 Operaciones Aeroportuarias:** resumen diario de salidas, llegadas y cancelaciones de cada aeropuerto.

DataMart seleccionado: DM1, porque tiene el detalle de cada vuelo (los otros dos se pueden obtener de él), responde los seis objetivos y sus dimensiones se reutilizan en DM2 y DM3.

Modelo conceptual: proceso de negocio «operación de un vuelo programado»; hecho **Vuelo**; dimensiones con sus jerarquías: Fecha (año → trimestre → mes → fecha, y día de la semana), Hora de salida (franja horaria → hora), Aerolínea, Aeropuerto (región → estado → ciudad → aeropuerto), que se usa dos veces, como origen y como destino, y Motivo de cancelación (Figura 1).

Granularidad: cada registro de la tabla de hechos es **un vuelo programado de una aerolínea en una fecha** (una fila de flights.csv), identificado por la fecha, la aerolínea, el número de vuelo, el aeropuerto de origen y la hora programada de salida; ≈ 5,8 millones de registros.



Figura 1. Modelo conceptual del DataMart Puntualidad de Vuelos: hecho, dimensiones y jerarquías.

4. Modelado Lógico del DataMart

Esquema en estrella (Figura 2). Cada dimensión se relaciona 1:N con la tabla de hechos mediante su clave sustituta (PK) y la clave foránea (FK) correspondiente:

Tabla	Atributos
fact_vuelo	PK sk_vuelo; FK sk_fecha, sk_hora_salida, sk_aerolinea, sk_aeropuerto_origen, sk_aeropuerto_destino, sk_motivo_cancelacion; dimensiones degeneradas: numero_vuelo, matricula_avion, salida_programada; métricas en minutos: retraso_salida_min, retraso_llegada_min, taxi_salida_min, taxi_llegada_min, tiempo_programado_min, tiempo_real_min, tiempo_aire_min, retraso_aerolinea_min, retraso_clima_min, retraso_sistema_aereo_min, retraso_seguridad_min, retraso_avion_tardio_min; distancia_millas; indicadores 0/1: es_cancelado, es_desviado, es_retrasado, es_puntual; fecha_carga (auditoría)
dim_fecha	PK sk_fecha (AAAAMMDD); fecha, dia, dia_semana, nombre_dia, es_fin_de_semana, mes, nombre_mes, trimestre, anio
dim_hora	PK sk_hora (0 a 23); hora_texto, franja_horaria
dim_aerolinea	PK sk_aerolinea; codigo_iata, nombre_aerolinea
dim_aeropuerto	PK sk_aeropuerto; codigo_iata, nombre_aeropuerto, ciudad, estado, region, pais, latitud, longitud

dim_motivo_cancelacion	PK sk_motivo_cancelacion; codigo_motivo (N, A, B, C, D), descripcion
------------------------	--

- **Claves:** las claves sustitutas (sk_*) son enteros generados por el DBMS; los códigos IATA del dataset son claves naturales únicas que el ETL usa para buscar la clave sustituta. dim_aeropuerto se relaciona dos veces con los hechos (origen y destino).
- **Métricas aditivas:** minutos de retraso (total y por causa), tiempos, distancia e indicadores 0/1 (su suma cuenta vuelos cancelados, retrasados o puntuales).
- **Métricas semiaditivas:** no hay en este hecho, porque cada vuelo es un evento independiente y no un saldo acumulado.
- **Métricas no aditivas:** porcentajes de puntualidad y de cancelación, y promedios; se recalculan desde sus componentes.

Verificación: OE1 usa es_puntual por aerolínea y mes; OE2, es_cancelado y es_desviado por aerolínea y motivo; OE3, los minutos por causa; OE4, retraso_llegada_min por aeropuertos de origen y destino; OE5, retraso_salida_min por franja horaria y día; OE6, taxi_salida_min por aeropuerto de origen. Todos los objetivos se pueden responder con el modelo.




Figura 2. Modelo lógico del DataMart Puntualidad de Vuelos (esquema en estrella).

PK = clave primaria (sustituta); FK = clave foránea, con la tabla a la que apunta; NK = clave natural única; DD = dimensión degenerada; ||—< = relación 1:N. dim_aeropuerto se relaciona dos veces con fact_vuelo (origen y destino).

5. Modelado Físico del DataMart

Se implementó en **PostgreSQL 16** (base y esquema dw_vuelos) con scripts SQL que crean las cinco dimensiones y la tabla de hechos, los índices y los datos fijos (fechas 2014–2016, las 24 horas y los motivos de cancelación).

- **Tipos de datos:** claves INTEGER/BIGINT IDENTITY; minutos y distancia SMALLINT (los retrasos negativos indican adelanto); indicadores SMALLINT; fecha DATE y hora programada TIME; códigos VARCHAR(3).
- **Restricciones e integridad referencial:** PK en todas las tablas, UNIQUE en los códigos IATA y en la clave natural del vuelo, seis FK obligatorias (dos hacia dim_aeropuerto) y reglas CHECK (distancia > 0, un vuelo cancelado debe tener motivo, es_retrasado = 1 solo si llegó con 15 minutos o más de retraso). Se probó que el DBMS rechaza aerolíneas inexistentes, vuelos cancelados sin motivo, vuelos duplicados, distancias negativas y el borrado de aeropuertos con vuelos.
- **Índices y orientación al análisis y al ETL:** índices en cada FK, en (aerolínea, fecha), en la ruta (origen, destino) y un índice parcial de vuelos cancelados; la clave natural única permite recargar sin duplicar y el miembro «Desconocido» (-1) evita perder vuelos con códigos no encontrados.

La Figura 3 muestra el modelo físico implementado, obtenido del catálogo de PostgreSQL: cada tabla con sus columnas, tipos de datos, claves y columnas obligatorias. El script de creación completo está en el Anexo.




Figura 3. Modelo físico del DataMart Puntualidad de Vuelos en PostgreSQL 16 (esquema dw_vuelos).

PK = clave primaria; FK = clave foránea; UK = forma parte de una restricción UNIQUE; NN = NOT NULL; IDENTITY = valor generado por el DBMS; ||—< = relación 1:N. dim_aeropuerto se relaciona dos veces con fact_vuelo (origen y destino).

Anexo. Script del modelo físico (PostgreSQL 16)

Scripts 01_crear_esquema_y_tablas.sql y 02_crear_indices.sql, sin los comentarios:

```
DROP SCHEMA IF EXISTS dw_vuelos CASCADE;
```

```
CREATE SCHEMA dw_vuelos;
```

```
SET search_path TO dw_vuelos;
```

```
CREATE TABLE dim_fecha (  
    sk_fecha INTEGER NOT NULL,  
    fecha DATE NOT NULL,  
    dia SMALLINT NOT NULL,  
    dia_semana SMALLINT NOT NULL,  
    nombre_dia VARCHAR(10) NOT NULL,  
    es_fin_de_semana BOOLEAN NOT NULL,  
    mes SMALLINT NOT NULL,  
    nombre_mes VARCHAR(10) NOT NULL,  
    trimestre SMALLINT NOT NULL,  
    anio SMALLINT NOT NULL,  
    CONSTRAINT pk_dim_fecha PRIMARY KEY (sk_fecha),  
    CONSTRAINT uq_dim_fecha_fecha UNIQUE (fecha),  
    CONSTRAINT ck_dim_fecha_sk CHECK (sk_fecha = EXTRACT(YEAR FROM  
    fecha) * 10000  
        + EXTRACT(MONTH FROM fecha) * 100  
        + EXTRACT(DAY FROM fecha)),  
    CONSTRAINT ck_dim_fecha_dia CHECK (dia BETWEEN 1 AND 31),  
    CONSTRAINT ck_dim_fecha_dia_semana CHECK (dia_semana BETWEEN 1  
    AND 7),  
    CONSTRAINT ck_dim_fecha_mes CHECK (mes BETWEEN 1 AND 12),  
    CONSTRAINT ck_dim_fecha_trimestre CHECK (trimestre BETWEEN 1 AND 4)  
);
```

```
CREATE TABLE dim_hora (  
    sk_hora SMALLINT NOT NULL,  
    hora_texto CHAR(5) NOT NULL,  
    franja_horaria VARCHAR(10) NOT NULL,  
    CONSTRAINT pk_dim_hora PRIMARY KEY (sk_hora),  
    CONSTRAINT ck_dim_hora CHECK (sk_hora BETWEEN 0 AND 23),  
    CONSTRAINT ck_dim_hora_franja CHECK (franja_horaria IN ('Madrugada',  
    'Mañana', 'Tarde', 'Noche'))  
);
```

```
CREATE TABLE dim_aerolinea (  
    sk_aerolinea INTEGER GENERATED BY DEFAULT AS IDENTITY,  
    codigo_iata VARCHAR(3) NOT NULL,  
    nombre_aerolinea VARCHAR(100) NOT NULL,  
    CONSTRAINT pk_dim_aerolinea PRIMARY KEY (sk_aerolinea),  
    CONSTRAINT uq_dim_aerolinea_codigo UNIQUE (codigo_iata)  
);
```

```

CREATE TABLE dim_aeropuerto (
    sk_aeropuerto INTEGER GENERATED BY DEFAULT AS IDENTITY,
    codigo_iata VARCHAR(3) NOT NULL,
    nombre_aeropuerto VARCHAR(150) NOT NULL,
    ciudad VARCHAR(80) NOT NULL,
    estado CHAR(2) NOT NULL,
    region VARCHAR(15) NOT NULL,
    pais VARCHAR(30) NOT NULL,
    latitud NUMERIC(9,6) NULL,
    longitud NUMERIC(9,6) NULL,
    CONSTRAINT pk_dim_aeropuerto PRIMARY KEY (sk_aeropuerto),
    CONSTRAINT uq_dim_aeropuerto_codigo UNIQUE (codigo_iata),
    CONSTRAINT ck_dim_aeropuerto_region CHECK (region IN
        ('Noreste', 'Medio Oeste', 'Sur', 'Oeste', 'Territorios', 'Desconocida')),
    CONSTRAINT ck_dim_aeropuerto_latitud CHECK (latitud BETWEEN -90 AND
        90),
    CONSTRAINT ck_dim_aeropuerto_longitud CHECK (longitud BETWEEN -180
        AND 180)
);

```

```

CREATE TABLE dim_motivo_cancelacion (
    sk_motivo_cancelacion SMALLINT NOT NULL,
    codigo_motivo CHAR(1) NOT NULL,
    descripcion VARCHAR(40) NOT NULL,
    CONSTRAINT pk_dim_motivo_cancelacion PRIMARY KEY
        (sk_motivo_cancelacion),
    CONSTRAINT uq_dim_motivo_cancelacion_codigo UNIQUE (codigo_motivo),
    CONSTRAINT ck_dim_motivo_cancelacion_codigo CHECK (codigo_motivo IN
        ('N', 'A', 'B', 'C', 'D'))
);

```

```

CREATE TABLE fact_vuelo (
    sk_vuelo BIGINT GENERATED BY DEFAULT AS IDENTITY,
    sk_fecha INTEGER NOT NULL,
    sk_hora_salida SMALLINT NOT NULL,
    sk_aerolinea INTEGER NOT NULL,
    sk_aeropuerto_origen INTEGER NOT NULL,
    sk_aeropuerto_destino INTEGER NOT NULL,
    sk_motivo_cancelacion SMALLINT NOT NULL,
    numero_vuelo INTEGER NOT NULL,
    matricula_avion VARCHAR(10) NULL,
    salida_programada TIME NOT NULL,
    retraso_salida_min SMALLINT NULL,
    retraso_llegada_min SMALLINT NULL,
    taxi_salida_min SMALLINT NULL,
    taxi_llegada_min SMALLINT NULL,
    tiempo_programado_min SMALLINT NULL,
    tiempo_real_min SMALLINT NULL,
    tiempo_aire_min SMALLINT NULL,
    distancia_millas SMALLINT NOT NULL,

```

retraso_aerolinea_min SMALLINT NOT NULL DEFAULT 0,
retraso_clima_min SMALLINT NOT NULL DEFAULT 0,
retraso_sistema_aereo_min SMALLINT NOT NULL DEFAULT 0,
retraso_seguridad_min SMALLINT NOT NULL DEFAULT 0,
retraso_avion_tardio_min SMALLINT NOT NULL DEFAULT 0,
es_cancelado SMALLINT NOT NULL DEFAULT 0,
es_desviado SMALLINT NOT NULL DEFAULT 0,
es_retrasado SMALLINT NOT NULL DEFAULT 0,
es_puntual SMALLINT NOT NULL DEFAULT 0,
fecha_carga TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP,

CONSTRAINT pk_fact_vuelo PRIMARY KEY (sk_vuelo),
CONSTRAINT uq_fact_vuelo_natural UNIQUE (sk_fecha, sk_aerolinea,
numero_vuelo,
sk_aeropuerto_origen, salida_programada),

CONSTRAINT fk_fact_vuelo_fecha FOREIGN KEY (sk_fecha) REFERENCES
dim_fecha (sk_fecha),
CONSTRAINT fk_fact_vuelo_hora FOREIGN KEY (sk_hora_salida)
REFERENCES dim_hora (sk_hora),
CONSTRAINT fk_fact_vuelo_aerolinea FOREIGN KEY (sk_aerolinea)
REFERENCES dim_aerolinea (sk_aerolinea),
CONSTRAINT fk_fact_vuelo_origen FOREIGN KEY (sk_aeropuerto_origen)
REFERENCES dim_aeropuerto (sk_aeropuerto),
CONSTRAINT fk_fact_vuelo_destino FOREIGN KEY (sk_aeropuerto_destino)
REFERENCES dim_aeropuerto (sk_aeropuerto),
CONSTRAINT fk_fact_vuelo_motivo FOREIGN KEY (sk_motivo_cancelacion)
REFERENCES dim_motivo_cancelacion (sk_motivo_cancelacion),

CONSTRAINT ck_fact_vuelo_numero CHECK (numero_vuelo > 0),
CONSTRAINT ck_fact_vuelo_distancia CHECK (distancia_millas > 0),
CONSTRAINT ck_fact_vuelo_taxi CHECK (taxi_salida_min >= 0 AND
taxi_llegada_min >= 0),
CONSTRAINT ck_fact_vuelo_tiempos CHECK (tiempo_programado_min > 0
AND tiempo_real_min > 0 AND tiempo_aire_min > 0),
CONSTRAINT ck_fact_vuelo_causas CHECK (
retraso_aerolinea_min >= 0 AND retraso_clima_min >= 0 AND
retraso_sistema_aereo_min >= 0 AND
retraso_seguridad_min >= 0 AND retraso_avion_tardio_min >= 0),
CONSTRAINT ck_fact_vuelo_ruta CHECK (sk_aeropuerto_origen <>
sk_aeropuerto_destino OR sk_aeropuerto_origen = -1),

CONSTRAINT ck_fact_vuelo_indicadores CHECK (
es_cancelado IN (0, 1) AND es_desviado IN (0, 1) AND es_retrasado IN
(0, 1) AND es_puntual IN (0, 1)),
CONSTRAINT ck_fact_vuelo_un_estado CHECK (es_cancelado + es_desviado
+ es_retrasado + es_puntual <= 1),
CONSTRAINT ck_fact_vuelo_cancelado CHECK ((es_cancelado = 1) =
(sk_motivo_cancelacion <> 0)),

```
CONSTRAINT ck_fact_vuelo_cancelado_sin_llegada CHECK (es_cancelado =  
0 OR retraso_llegada_min IS NULL),  
CONSTRAINT ck_fact_vuelo_retrasado CHECK ((es_retrasado = 1) =  
(COALESCE(retraso_llegada_min, -1) >= 15)),  
CONSTRAINT ck_fact_vuelo_puntual CHECK ((es_puntual = 1) =  
(COALESCE(retraso_llegada_min, 15) < 15))  
);
```

```
SET search_path TO dw_vuelos;
```

```
CREATE INDEX ix_fact_vuelo_hora ON fact_vuelo (sk_hora_salida);  
CREATE INDEX ix_fact_vuelo_destino ON fact_vuelo (sk_aeropuerto_destino);  
CREATE INDEX ix_fact_vuelo_motivo ON fact_vuelo (sk_motivo_cancelacion);
```

```
CREATE INDEX ix_fact_vuelo_aerolinea_fecha ON fact_vuelo (sk_aerolinea,  
sk_fecha);  
CREATE INDEX ix_fact_vuelo_ruta ON fact_vuelo (sk_aeropuerto_origen,  
sk_aeropuerto_destino);
```

```
CREATE INDEX ix_fact_vuelo_cancelados ON fact_vuelo (sk_aerolinea,  
sk_motivo_cancelacion)  
WHERE es_cancelado = 1;
```

```
CREATE INDEX ix_dim_fecha_anio_mes ON dim_fecha (anio, mes);  
CREATE INDEX ix_dim_fecha_dia_semana ON dim_fecha (dia_semana);  
CREATE INDEX ix_dim_hora_franja ON dim_hora (franja_horaria);  
CREATE INDEX ix_dim_aeropuerto_region ON dim_aeropuerto (region, estado);  
CREATE INDEX ix_dim_aeropuerto_ciudad ON dim_aeropuerto (ciudad);
```