

[Universidad] – Base de Datos III – Proyecto: Implementación de un Data Warehouse

Primera Presentación (puntos 1 a 5): Data Warehouse de puntualidad de vuelos en EE. UU. (2015)

Integrantes: Jhonatan Moisés Villca, [Integrante 2], [Integrante 3] – Docente: Rodnie Montaña Aguilera

1. Tema del Proyecto

Tema: análisis de la puntualidad, los retrasos y las cancelaciones de los vuelos comerciales nacionales de Estados Unidos en 2015. **Conjunto de datos:** «2015 Flight Delays and Cancellations» de Kaggle, publicado por el Departamento de Transporte de EE. UU. con datos de la Oficina de Estadísticas de Transporte (BTS). Tiene tres archivos CSV: flights.csv (≈ 5,8 millones de vuelos con fecha, aerolínea, número de vuelo, aeropuertos de origen y destino, horarios programados y reales, retrasos, tiempos de rodaje y de vuelo, distancia, cancelación, desvío y minutos de retraso por causa), airlines.csv (14 aerolíneas) y airports.csv (322 aeropuertos con ciudad, estado y coordenadas).

Suficiencia de los datos: cada vuelo es un evento medible con métricas numéricas (minutos de retraso, tiempos, distancia) y con descriptores que forman dimensiones con jerarquías: fecha → mes → trimestre, hora → franja horaria y aeropuerto → ciudad → estado → región. El volumen y los problemas de calidad (horas en formato hhmm, valores vacíos en vuelos cancelados o desviados, aeropuertos con códigos numéricos en lugar del código IATA en octubre) justifican un Data Warehouse y un proceso ETL.

Contexto y necesidad de análisis: según la BTS, un vuelo está retrasado si llega 15 minutos o más después de lo programado, y las aerolíneas informan la causa (la propia aerolínea, el clima, el sistema aéreo nacional, la seguridad o la llegada tardía del avión). Los datos están en un solo archivo plano, útil para registrar vuelos pero no para analizarlos. La necesidad es **saber dónde, cuándo y por qué se producen los retrasos y las cancelaciones** (por aerolínea, aeropuerto, ruta, horario y causa), para que aerolíneas, aeropuertos y pasajeros tomen mejores decisiones. No es un tema de ventas ni de inventario: es el análisis del desempeño operativo de un sistema de transporte.

2. Objetivos del Data Warehouse

Objetivo general: implementar un Data Warehouse con un DataMart de Puntualidad de Vuelos que integre los vuelos de 2015 para analizar la puntualidad, los retrasos y las cancelaciones por aerolínea, aeropuerto, ruta y período, mediante indicadores, consultas, cubos OLAP, reportes y cuadros de mando.

Objetivos específicos (medibles con el indicador indicado):

Cód.	Objetivo específico	Indicador
OE1	Medir la puntualidad de cada aerolínea por mes.	% de vuelos puntuales
OE2	Cuantificar las cancelaciones y los desvíos por aerolínea y motivo.	% de cancelación y de desvío
OE3	Identificar qué causas generan más minutos de retraso.	% de minutos por causa
OE4	Determinar los aeropuertos y rutas con mayor retraso.	Retraso promedio de llegada

OE5	Analizar los retrasos según la franja horaria y el día de la semana.	Retraso promedio de salida
OE6	Evaluar la eficiencia en tierra de cada aeropuerto.	Tiempo promedio de rodaje

Estos objetivos definen el hecho (vuelo), las dimensiones (fecha, hora, aerolínea, aeropuerto y motivo de cancelación), las métricas, la granularidad y los reportes y cuadros de mando de la segunda presentación.

3. Modelado Conceptual del DataMart

Tres DataMarts posibles:

- **DM1 Puntualidad de Vuelos:** cada vuelo con sus retrasos, cancelación y desvío.
- **DM2 Causas de Retraso:** minutos de retraso de cada vuelo repartidos por causa.
- **DM3 Operaciones Aeroportuarias:** resumen diario de salidas, llegadas y cancelaciones de cada aeropuerto.

DataMart seleccionado: DM1, porque tiene el detalle de cada vuelo (los otros dos se pueden obtener de él), responde los seis objetivos y sus dimensiones se reutilizan en DM2 y DM3.

Modelo conceptual: proceso de negocio «operación de un vuelo programado»; hecho **Vuelo**; dimensiones con sus jerarquías: Fecha (año → trimestre → mes → fecha, y día de la semana), Hora de salida (franja horaria → hora), Aerolínea, Aeropuerto (región → estado → ciudad → aeropuerto), que se usa dos veces, como origen y como destino, y Motivo de cancelación.

Granularidad: cada registro de la tabla de hechos es **un vuelo programado de una aerolínea en una fecha** (una fila de flights.csv), identificado por la fecha, la aerolínea, el número de vuelo, el aeropuerto de origen y la hora programada de salida; ≈ 5,8 millones de registros.

4. Modelado Lógico del DataMart

Esquema en estrella. Cada dimensión se relaciona 1:N con la tabla de hechos mediante su clave sustituta (PK) y la clave foránea (FK) correspondiente:

Tabla	Atributos
fact_vuelo	PK sk_vuelo; FK sk_fecha, sk_hora_salida, sk_aerolinea, sk_aeropuerto_origen, sk_aeropuerto_destino, sk_motivo_cancelacion; numero_vuelo, matricula_avion, salida_programada; métricas en minutos: retraso_salida_min, retraso_llegada_min, taxi_salida_min, taxi_llegada_min, tiempo_aire_min, retraso por causa (aerolínea, clima, sistema aéreo, seguridad, avión tardío); distancia_millas; indicadores 0/1: es_cancelado, es_desviado, es_retrasado, es_puntual
dim_fecha	PK sk_fecha (AAAAMMDD); fecha, dia_semana, es_fin_de_semana, mes, trimestre, anio
dim_hora	PK sk_hora (0 a 23); hora_texto, franja_horaria
dim_aerolinea	PK sk_aerolinea; codigo_iata, nombre_aerolinea
dim_aeropuerto	PK sk_aeropuerto; codigo_iata, nombre_aeropuerto, ciudad, estado, region, latitud, longitud

dim_motivo_cancelacion	PK sk_motivo_cancelacion; codigo_motivo (N, A, B, C, D), descripcion
------------------------	--

- **Claves:** las claves sustitutas (sk_*) son enteros generados por el DBMS; los códigos IATA del dataset son claves naturales únicas que el ETL usa para buscar la clave sustituta. dim_aeropuerto se relaciona dos veces con los hechos (origen y destino).
- **Métricas aditivas:** minutos de retraso (total y por causa), tiempos, distancia e indicadores 0/1 (su suma cuenta vuelos cancelados, retrasados o puntuales).
- **Métricas semiaditivas:** no hay en este hecho, porque cada vuelo es un evento independiente y no un saldo acumulado.
- **Métricas no aditivas:** porcentajes de puntualidad y de cancelación, y promedios; se recalculan desde sus componentes.

Verificación: OE1 usa es_puntual por aerolínea y mes; OE2, es_cancelado y es_desviado por aerolínea y motivo; OE3, los minutos por causa; OE4, retraso_llegada_min por aeropuertos de origen y destino; OE5, retraso_salida_min por franja horaria y día; OE6, taxi_salida_min por aeropuerto de origen. Todos los objetivos se pueden responder con el modelo.

5. Modelado Físico del DataMart

Se implementó en **PostgreSQL 16** (base y esquema dw_vuelos) con scripts SQL que crean las cinco dimensiones y la tabla de hechos, los índices y los datos fijos (fechas 2014–2016, las 24 horas y los motivos de cancelación).

- **Tipos de datos:** claves INTEGER/BIGINT IDENTITY; minutos y distancia SMALLINT (los retrasos negativos indican adelanto); indicadores SMALLINT; fecha DATE y hora programada TIME; códigos VARCHAR(3).
- **Restricciones e integridad referencial:** PK en todas las tablas, UNIQUE en los códigos IATA y en la clave natural del vuelo, seis FK obligatorias (dos hacia dim_aeropuerto) y reglas CHECK (distancia > 0, un vuelo cancelado debe tener motivo, es_retrasado = 1 solo si llegó con 15 minutos o más de retraso). Se probó que el DBMS rechaza aerolíneas inexistentes, vuelos duplicados y el borrado de aeropuertos con vuelos.
- **Índices y orientación al análisis y al ETL:** índices en cada FK, en (aerolínea, fecha), en la ruta (origen, destino) y un índice parcial de vuelos cancelados; la clave natural única permite recargar sin duplicar y el miembro «Desconocido» (-1) evita perder vuelos con códigos no encontrados.

La Figura 1 muestra el modelo físico implementado, obtenido del catálogo de PostgreSQL: cada tabla con sus columnas, tipos de datos, claves y columnas obligatorias. El script de creación completo está en el Anexo.




Figura 1. Modelo físico del DataMart Puntualidad de Vuelos en PostgreSQL 16 (esquema dw_vuelos).

PK = clave primaria; FK = clave foránea; UK = forma parte de una restricción UNIQUE; NN = NOT NULL; IDENTITY = valor generado por el DBMS; ||—< = relación 1:N. dim_aeropuerto se relaciona dos veces con el fact_vuelo (origen y destino).

Anexo. Script del modelo físico (PostgreSQL 16)

Scripts 01_crear_esquema_y_tablas.sql y 02_crear_indices.sql, sin los comentarios:

```
DROP SCHEMA IF EXISTS dw_vuelos CASCADE;
```

```
CREATE SCHEMA dw_vuelos;
```

```
SET search_path TO dw_vuelos;
```

```
CREATE TABLE dim_fecha (  
    sk_fecha INTEGER NOT NULL,  
    fecha DATE NOT NULL,  
    dia SMALLINT NOT NULL,  
    dia_semana SMALLINT NOT NULL,  
    nombre_dia VARCHAR(10) NOT NULL,  
    es_fin_de_semana BOOLEAN NOT NULL,  
    mes SMALLINT NOT NULL,  
    nombre_mes VARCHAR(10) NOT NULL,  
    trimestre SMALLINT NOT NULL,  
    anio SMALLINT NOT NULL,  
    CONSTRAINT pk_dim_fecha PRIMARY KEY (sk_fecha),  
    CONSTRAINT uq_dim_fecha_fecha UNIQUE (fecha),  
    CONSTRAINT ck_dim_fecha_sk CHECK (sk_fecha = EXTRACT(YEAR FROM  
    fecha) * 10000  
        + EXTRACT(MONTH FROM fecha) * 100  
        + EXTRACT(DAY FROM fecha)),  
    CONSTRAINT ck_dim_fecha_dia CHECK (dia BETWEEN 1 AND 31),  
    CONSTRAINT ck_dim_fecha_dia_semana CHECK (dia_semana BETWEEN 1  
    AND 7),  
    CONSTRAINT ck_dim_fecha_mes CHECK (mes BETWEEN 1 AND 12),  
    CONSTRAINT ck_dim_fecha_trimestre CHECK (trimestre BETWEEN 1 AND 4)  
);
```

```
CREATE TABLE dim_hora (  
    sk_hora SMALLINT NOT NULL,  
    hora_texto CHAR(5) NOT NULL,  
    franja_horaria VARCHAR(10) NOT NULL,  
    CONSTRAINT pk_dim_hora PRIMARY KEY (sk_hora),  
    CONSTRAINT ck_dim_hora CHECK (sk_hora BETWEEN 0 AND 23),  
    CONSTRAINT ck_dim_hora_franja CHECK (franja_horaria IN ('Madrugada',  
    'Mañana', 'Tarde', 'Noche'))  
);
```

```
CREATE TABLE dim_aerolinea (  
    sk_aerolinea INTEGER GENERATED BY DEFAULT AS IDENTITY,  
    codigo_iata VARCHAR(3) NOT NULL,  
    nombre_aerolinea VARCHAR(100) NOT NULL,  
    CONSTRAINT pk_dim_aerolinea PRIMARY KEY (sk_aerolinea),  
    CONSTRAINT uq_dim_aerolinea_codigo UNIQUE (codigo_iata)  
);
```

```

CREATE TABLE dim_aeropuerto (
    sk_aeropuerto INTEGER GENERATED BY DEFAULT AS IDENTITY,
    codigo_iata VARCHAR(3) NOT NULL,
    nombre_aeropuerto VARCHAR(150) NOT NULL,
    ciudad VARCHAR(80) NOT NULL,
    estado CHAR(2) NOT NULL,
    region VARCHAR(15) NOT NULL,
    pais VARCHAR(30) NOT NULL,
    latitud NUMERIC(9,6) NULL,
    longitud NUMERIC(9,6) NULL,
    CONSTRAINT pk_dim_aeropuerto PRIMARY KEY (sk_aeropuerto),
    CONSTRAINT uq_dim_aeropuerto_codigo UNIQUE (codigo_iata),
    CONSTRAINT ck_dim_aeropuerto_region CHECK (region IN
        ('Noreste', 'Medio Oeste', 'Sur', 'Oeste', 'Territorios', 'Desconocida')),
    CONSTRAINT ck_dim_aeropuerto_latitud CHECK (latitud BETWEEN -90 AND
        90),
    CONSTRAINT ck_dim_aeropuerto_longitud CHECK (longitud BETWEEN -180
        AND 180)
);

```

```

CREATE TABLE dim_motivo_cancelacion (
    sk_motivo_cancelacion SMALLINT NOT NULL,
    codigo_motivo CHAR(1) NOT NULL,
    descripcion VARCHAR(40) NOT NULL,
    CONSTRAINT pk_dim_motivo_cancelacion PRIMARY KEY
        (sk_motivo_cancelacion),
    CONSTRAINT uq_dim_motivo_cancelacion_codigo UNIQUE (codigo_motivo),
    CONSTRAINT ck_dim_motivo_cancelacion_codigo CHECK (codigo_motivo IN
        ('N', 'A', 'B', 'C', 'D'))
);

```

```

CREATE TABLE fact_vuelo (
    sk_vuelo BIGINT GENERATED BY DEFAULT AS IDENTITY,
    sk_fecha INTEGER NOT NULL,
    sk_hora_salida SMALLINT NOT NULL,
    sk_aerolinea INTEGER NOT NULL,
    sk_aeropuerto_origen INTEGER NOT NULL,
    sk_aeropuerto_destino INTEGER NOT NULL,
    sk_motivo_cancelacion SMALLINT NOT NULL,
    numero_vuelo INTEGER NOT NULL,
    matricula_avion VARCHAR(10) NULL,
    salida_programada TIME NOT NULL,
    retraso_salida_min SMALLINT NULL,
    retraso_llegada_min SMALLINT NULL,
    taxi_salida_min SMALLINT NULL,
    taxi_llegada_min SMALLINT NULL,
    tiempo_programado_min SMALLINT NULL,
    tiempo_real_min SMALLINT NULL,
    tiempo_aire_min SMALLINT NULL,
    distancia_millas SMALLINT NOT NULL,

```

retraso_aerolinea_min SMALLINT NOT NULL DEFAULT 0,
retraso_clima_min SMALLINT NOT NULL DEFAULT 0,
retraso_sistema_aereo_min SMALLINT NOT NULL DEFAULT 0,
retraso_seguridad_min SMALLINT NOT NULL DEFAULT 0,
retraso_avion_tardio_min SMALLINT NOT NULL DEFAULT 0,
es_cancelado SMALLINT NOT NULL DEFAULT 0,
es_desviado SMALLINT NOT NULL DEFAULT 0,
es_retrasado SMALLINT NOT NULL DEFAULT 0,
es_puntual SMALLINT NOT NULL DEFAULT 0,
fecha_carga TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP,

CONSTRAINT pk_fact_vuelo PRIMARY KEY (sk_vuelo),
CONSTRAINT uq_fact_vuelo_natural UNIQUE (sk_fecha, sk_aerolinea,
numero_vuelo,
sk_aeropuerto_origen, salida_programada),

CONSTRAINT fk_fact_vuelo_fecha FOREIGN KEY (sk_fecha) REFERENCES
dim_fecha (sk_fecha),
CONSTRAINT fk_fact_vuelo_hora FOREIGN KEY (sk_hora_salida)
REFERENCES dim_hora (sk_hora),
CONSTRAINT fk_fact_vuelo_aerolinea FOREIGN KEY (sk_aerolinea)
REFERENCES dim_aerolinea (sk_aerolinea),
CONSTRAINT fk_fact_vuelo_origen FOREIGN KEY (sk_aeropuerto_origen)
REFERENCES dim_aeropuerto (sk_aeropuerto),
CONSTRAINT fk_fact_vuelo_destino FOREIGN KEY (sk_aeropuerto_destino)
REFERENCES dim_aeropuerto (sk_aeropuerto),
CONSTRAINT fk_fact_vuelo_motivo FOREIGN KEY (sk_motivo_cancelacion)
REFERENCES dim_motivo_cancelacion (sk_motivo_cancelacion),

CONSTRAINT ck_fact_vuelo_numero CHECK (numero_vuelo > 0),
CONSTRAINT ck_fact_vuelo_distancia CHECK (distancia_millas > 0),
CONSTRAINT ck_fact_vuelo_taxi CHECK (taxi_salida_min >= 0 AND
taxi_llegada_min >= 0),
CONSTRAINT ck_fact_vuelo_tiempos CHECK (tiempo_programado_min > 0
AND tiempo_real_min > 0 AND tiempo_aire_min > 0),
CONSTRAINT ck_fact_vuelo_causas CHECK (
retraso_aerolinea_min >= 0 AND retraso_clima_min >= 0 AND
retraso_sistema_aereo_min >= 0 AND
retraso_seguridad_min >= 0 AND retraso_avion_tardio_min >= 0),
CONSTRAINT ck_fact_vuelo_ruta CHECK (sk_aeropuerto_origen <>
sk_aeropuerto_destino OR sk_aeropuerto_origen = -1),

CONSTRAINT ck_fact_vuelo_indicadores CHECK (
es_cancelado IN (0, 1) AND es_desviado IN (0, 1) AND es_retrasado IN
(0, 1) AND es_puntual IN (0, 1)),
CONSTRAINT ck_fact_vuelo_un_estado CHECK (es_cancelado + es_desviado
+ es_retrasado + es_puntual <= 1),
CONSTRAINT ck_fact_vuelo_cancelado CHECK ((es_cancelado = 1) =
(sk_motivo_cancelacion <> 0)),

```
CONSTRAINT ck_fact_vuelo_cancelado_sin_llegada CHECK (es_cancelado =  
0 OR retraso_llegada_min IS NULL),  
CONSTRAINT ck_fact_vuelo_retrasado CHECK ((es_retrasado = 1) =  
(COALESCE(retraso_llegada_min, -1) >= 15)),  
CONSTRAINT ck_fact_vuelo_puntual CHECK ((es_puntual = 1) =  
(COALESCE(retraso_llegada_min, 15) < 15))  
);
```

```
SET search_path TO dw_vuelos;
```

```
CREATE INDEX ix_fact_vuelo_hora ON fact_vuelo (sk_hora_salida);  
CREATE INDEX ix_fact_vuelo_destino ON fact_vuelo (sk_aeropuerto_destino);  
CREATE INDEX ix_fact_vuelo_motivo ON fact_vuelo (sk_motivo_cancelacion);
```

```
CREATE INDEX ix_fact_vuelo_aerolinea_fecha ON fact_vuelo (sk_aerolinea,  
sk_fecha);  
CREATE INDEX ix_fact_vuelo_ruta ON fact_vuelo (sk_aeropuerto_origen,  
sk_aeropuerto_destino);
```

```
CREATE INDEX ix_fact_vuelo_cancelados ON fact_vuelo (sk_aerolinea,  
sk_motivo_cancelacion)  
WHERE es_cancelado = 1;
```

```
CREATE INDEX ix_dim_fecha_anio_mes ON dim_fecha (anio, mes);  
CREATE INDEX ix_dim_fecha_dia_semana ON dim_fecha (dia_semana);  
CREATE INDEX ix_dim_hora_franja ON dim_hora (franja_horaria);  
CREATE INDEX ix_dim_aeropuerto_region ON dim_aeropuerto (region, estado);  
CREATE INDEX ix_dim_aeropuerto_ciudad ON dim_aeropuerto (ciudad);
```