



Materia / Asignatura: Base de Datos III

Docente / Profesor: Rodnie Montaña Aguilera

Estudiante / Integrantes:

- Jhonatan Moisés Villca
- Pedro Visir Valda

Proyecto: Análisis de la puntualidad, los retrasos y las cancelaciones de los vuelos comerciales nacionales de Estados Unidos en 2015

1. TEMA DEL PROYECTO

1.1 Tema seleccionado

El proyecto analiza la puntualidad de los vuelos comerciales nacionales de Estados Unidos durante el año 2015. Se estudian los retrasos, las cancelaciones y los desvíos de los vuelos según la aerolínea, el aeropuerto, la ruta, la fecha y la hora de salida.

1.2 Conjunto de datos

Los datos se obtuvieron de Kaggle, del conjunto de datos "2015 Flight Delays and Cancellations", publicado por el Departamento de Transporte de los Estados Unidos con información de la Oficina de Estadísticas de Transporte (BTS).

Enlace: <https://www.kaggle.com/datasets/usdot/flight-delays>

El conjunto de datos está formado por tres archivos CSV, que se describen en la Tabla 1.

Tabla 1. Archivos del conjunto de datos

Archivo	Contenido	Registros
flights.csv	Un registro por vuelo con la fecha, la aerolínea, el número de vuelo, los aeropuertos de origen y destino, los horarios, los retrasos, los tiempos de vuelo, la distancia, la cancelación, el desvío y las causas del retraso.	Más de 5,8 millones
airlines.csv	Código y nombre de cada aerolínea.	14
airports.csv	Código, nombre, ciudad, estado, país y coordenadas de cada aeropuerto.	322

La información es suficiente para construir un Data Warehouse. Cada vuelo es un hecho que se puede medir (minutos de retraso, tiempos y distancia) y tiene datos descriptivos que sirven como dimensiones, como la fecha, la aerolínea y los aeropuertos. Estas dimensiones tienen jerarquías naturales: las fechas se agrupan en meses, trimestres y años, y los aeropuertos en ciudades, estados y regiones.

1.3 Contexto de los datos y necesidad de análisis

En Estados Unidos, la BTS considera que un vuelo está retrasado cuando llega 15 minutos o más después de la hora programada. En ese caso la aerolínea informa la causa del retraso, que puede ser la propia aerolínea, el clima, el sistema nacional de aviación, la seguridad o la llegada tardía del avión desde un vuelo anterior. Los vuelos cancelados también tienen registrado el motivo de la cancelación.

Actualmente estos datos están en un archivo plano, que sirve para registrar los vuelos pero no para analizarlos. Por ejemplo, para saber qué aerolínea tuvo más retrasos en diciembre o cuál fue la causa más frecuente, habría que procesar millones de filas en cada consulta. La necesidad de análisis es conocer dónde, cuándo y por qué se producen los retrasos y las cancelaciones, para que las

aerolíneas y los aeropuertos puedan mejorar su puntualidad y los pasajeros puedan elegir mejor sus vuelos.

1.4 Justificación del tema

El tema no pertenece a los casos excluidos en la consigna, como ventas, inventarios, hoteles o restaurantes. Se trata del análisis del desempeño de un sistema de transporte, con un volumen grande de datos, varias causas de retraso y datos que necesitan limpieza antes de cargarse: horas guardadas como números (por ejemplo, 1530 para las 15:30), valores vacíos en los vuelos cancelados y códigos de aeropuerto numéricos en el mes de octubre. Por estas razones se justifica el diseño de un Data Warehouse y de un proceso ETL.

2. OBJETIVOS DEL DATA WAREHOUSE

2.1 Objetivo general

Diseñar e implementar un Data Warehouse que integre los datos de los vuelos nacionales de Estados Unidos del año 2015, para analizar la puntualidad, los retrasos y las cancelaciones por aerolínea, aeropuerto, ruta y período mediante indicadores, reportes y cuadros de mando.

2.2 Objetivos específicos

Los objetivos específicos se presentan en la Tabla 2. Cada uno tiene un indicador que permite medirlo con los datos del DataMart.

Tabla 2. Objetivos específicos e indicadores

N.º	Objetivo específico	Indicador
OE1	Medir la puntualidad de cada aerolínea por mes.	Porcentaje de vuelos que llegan con menos de 15 minutos de retraso.
OE2	Cuantificar las cancelaciones y los desvíos por aerolínea y por motivo.	Porcentaje de vuelos cancelados y desviados.
OE3	Identificar las causas que generan más minutos de retraso.	Porcentaje de minutos de retraso de cada causa.
OE4	Determinar las rutas y los aeropuertos con mayor retraso.	Promedio de minutos de retraso en la llegada.
OE5	Analizar los retrasos según la hora de salida y el día de la semana.	Promedio de minutos de retraso en la salida.
OE6	Evaluar el tiempo que los aviones pasan en tierra en cada aeropuerto.	Promedio de minutos de rodaje antes del despegue.

2.3 Relación de los objetivos con el diseño

A partir de estos objetivos se definió el diseño del DataMart. Todos se responden analizando vuelos, por lo que el hecho principal es el vuelo y la granularidad es un vuelo. Las dimensiones necesarias son la fecha, la hora de salida, la aerolínea, el aeropuerto y el motivo de cancelación. Las métricas son los minutos de retraso, los

tiempos de vuelo, la distancia y los indicadores de vuelo cancelado, desviado, retrasado o puntual.

En la segunda presentación cada objetivo tendrá un reporte, y los indicadores principales se reunirán en un cuadro de mando de puntualidad con filtros por aerolínea, aeropuerto y mes.

3. MODELADO CONCEPTUAL DEL DATAMART

3.1 DataMarts propuestos

Con los datos disponibles se identificaron tres posibles DataMarts, que se muestran en la Tabla 3.

Tabla 3. DataMarts propuestos

DataMart	Qué analiza	Cada registro representa
Puntualidad de Vuelos	La operación de cada vuelo: retrasos, cancelaciones y desvíos.	Un vuelo.
Causas de Retraso	Cómo se reparten los minutos de retraso entre sus causas.	Un vuelo retrasado y una de sus causas.
Operaciones Aeroportuarias	El movimiento diario de cada aeropuerto: salidas, llegadas y cancelaciones.	Un aeropuerto en un día.

3.2 DataMart seleccionado

Se eligió el DataMart de Puntualidad de Vuelos porque es el que aporta más valor: guarda el detalle de cada vuelo, permite responder los seis objetivos y los otros dos DataMarts se pueden obtener a partir de él, resumiendo sus datos por causa o por aeropuerto y día.

3.3 Modelo conceptual

El proceso de negocio es la operación de un vuelo programado. El hecho es el vuelo y se describe con seis dimensiones: la fecha, la hora de salida, la aerolínea, el aeropuerto de origen, el aeropuerto de destino y el motivo de cancelación. Los aeropuertos de origen y de destino son la misma dimensión usada en dos roles. La Figura 1 muestra el modelo con las jerarquías de cada dimensión.

3.4 Granularidad

Cada registro de la tabla de hechos representa un vuelo programado de una aerolínea en una fecha, es decir, una fila del archivo flights.csv. Un vuelo se identifica por su fecha, la aerolínea, el número de vuelo, el aeropuerto de origen y la hora programada de salida. Con esta granularidad, la tabla de hechos tendrá más de 5,8 millones de registros.



Figura 1. Modelo conceptual del DataMart Puntualidad de Vuelos.

4. MODELADO LÓGICO DEL DATAMART

4.1 Tablas de hechos y dimensiones

El modelo lógico es un esquema en estrella formado por una tabla de hechos y cinco tablas de dimensiones. La Tabla 4 detalla los atributos de cada tabla y la Figura 2, al final de este punto, muestra el diagrama del modelo.

Tabla 4. Tablas del modelo lógico

Tabla	Atributos
fact_vuelo (hechos)	sk_vuelo (PK); sk_fecha, sk_hora_salida, sk_aerolinea, sk_aeropuerto_origen, sk_aeropuerto_destino, sk_motivo_cancelacion (FK); numero_vuelo, matricula_avion, salida_programada; retraso_salida_min, retraso_llegada_min, taxi_salida_min, taxi_llegada_min, tiempo_programado_min, tiempo_real_min, tiempo_aire_min, distancia_millas; retraso_aerolinea_min, retraso_clima_min, retraso_sistema_aereo_min, retraso_seguridad_min, retraso_avion_tardio_min; es_cancelado, es_desviado, es_retrasado, es_puntual; fecha_carga
dim_fecha	sk_fecha (PK), fecha, dia, dia_semana, nombre_dia, es_fin_de_semana, mes, nombre_mes, trimestre, anio
dim_hora	sk_hora (PK), hora_texto, franja_horaria
dim_aerolinea	sk_aerolinea (PK), codigo_iata, nombre_aerolinea
dim_aeropuerto	sk_aeropuerto (PK), codigo_iata, nombre_aeropuerto, ciudad, estado, region, pais, latitud, longitud
dim_motivo_cancelacion	sk_motivo_cancelacion (PK), codigo_motivo, descripcion

4.2 Claves y relaciones

Cada dimensión tiene una clave sustituta (sk), que es un número generado por la base de datos y funciona como clave primaria. La tabla de hechos guarda una clave foránea hacia cada dimensión, y todas las relaciones son de uno a muchos: por ejemplo, una aerolínea tiene muchos vuelos, pero cada vuelo pertenece a una sola aerolínea.

Los códigos que vienen en los archivos, como el código IATA de aerolíneas y aeropuertos, se guardan como claves naturales y sirven para encontrar la clave sustituta durante la carga. La dimensión aeropuerto se relaciona dos veces con la tabla de hechos, una como origen y otra como destino. El número de vuelo, la matrícula del avión y la hora programada se guardan en la tabla de hechos como dimensiones degeneradas, porque no necesitan una tabla propia.

4.3 Origen de los datos

La Tabla 5 muestra cómo se usa cada columna de los archivos CSV en el DataMart.

Tabla 5. Columnas del conjunto de datos y su uso en el DataMart

Columna del dataset	Significado	En el DataMart
YEAR MONTH DAY DAY_OF_WEEK	Fecha del vuelo y día de la semana	dim_fecha (dimensión)
AIRLINE	Código de la aerolínea	dim_aerolinea (dimensión)
ORIGIN_AIRPORT DESTINATION_AIRPORT	Aeropuertos de origen y destino	dim_aeropuerto (dimensión)
SCHEDULED_DEPARTURE	Hora programada de salida	salida_programada (dimensión degenerada) dim_hora (dimensión)
CANCELLATION_REASON	Motivo de la cancelación	dim_motivo_cancelacion (dimensión)
FLIGHT_NUMBER TAIL_NUMBER	Número de vuelo y matrícula del avión	numero_vuelo matricula_avion (dimensiones degeneradas)
DEPARTURE_DELAY	Minutos de retraso en la salida	retraso_salida_min (métrica)
ARRIVAL_DELAY	Minutos de retraso en la llegada	retraso_llegada_min (métrica) es_retrasado y es_puntual (indicadores)
TAXI_OUT TAXI_IN	Minutos de rodaje antes del despegue y después del aterrizaje	taxi_salida_min taxi_llegada_min (métricas)

Columna del dataset	Significado	En el DataMart
SCHEDULED_TIME ELAPSED_TIME AIR_TIME	Duración programada, real y en el aire	tiempo_programado_min tiempo_real_min tiempo_aire_min (métricas)
DISTANCE	Distancia en millas	distancia_millas (métrica)
AIRLINE_DELAY WEATHER_DELAY AIR_SYSTEM_DELAY SECURITY_DELAY LATE_AIRCRAFT_DELAY	Minutos de retraso por cada causa	retraso_aerolinea_min retraso_clima_min retraso_sistema_aereo_min retraso_seguridad_min retraso_avion_tardio_min (métricas)
CANCELLED DIVERTED	Indican si el vuelo fue cancelado o desviado	es_cancelado es_desviado (indicadores)
DEPARTURE_TIME WHEELS_OFF WHEELS_ON SCHEDULED_ARRIVAL ARRIVAL_TIME	Horas reales y programadas de cada etapa del vuelo	No se cargan, porque lo necesario ya está en los retrasos y los tiempos
airlines.csv (todas)	Datos de cada aerolínea	dim_aerolinea (dimensión)
airports.csv (todas)	Datos de cada aeropuerto	dim_aeropuerto (dimensión); la región se obtiene del estado

4.4 Métricas y su clasificación

En la Tabla 6 se clasifican las métricas de la tabla de hechos según si se pueden sumar o no.

Tabla 6. Clasificación de las métricas

Métrica	Tipo	Motivo
Minutos de retraso en la salida y en la llegada	Aditiva	Se suman por aerolínea, aeropuerto o fecha para obtener el total de minutos de retraso.
Minutos de retraso por causa	Aditiva	La suma por causa muestra cuál genera más retraso.
Tiempos de rodaje, tiempo programado, tiempo real y tiempo en el aire	Aditiva	Se pueden sumar o promediar por cualquier dimensión.
Distancia	Aditiva	La suma da el total de millas voladas.
Indicadores de vuelo cancelado, desviado, retrasado y puntual (0 o 1)	Aditiva	La suma da la cantidad de vuelos de cada tipo.
Porcentajes de puntualidad y de cancelación, y promedios	No aditiva	No se pueden sumar; se calculan a partir de los totales.

No hay métricas semiaditivas, porque cada vuelo es un evento independiente y ninguna medida representa un saldo acumulado en el tiempo.

4.5 Verificación del modelo con los objetivos

La Tabla 7 muestra qué métricas y dimensiones se usan para responder cada objetivo específico.

Tabla 7. Verificación del modelo lógico

Objetivo	Métricas	Dimensiones
OE1	es_puntual, es_retrasado	Aerolínea y fecha (mes)
OE2	es_cancelado, es_desviado	Aerolínea y motivo de cancelación
OE3	Minutos de retraso por causa	Fecha y aerolínea
OE4	retraso_llegada_min	Aeropuerto de origen y de destino
OE5	retraso_salida_min, es_retrasado	Hora (franja horaria) y fecha (día de la semana)
OE6	taxi_salida_min	Aeropuerto de origen

Como se observa, todos los objetivos se pueden responder con las métricas y dimensiones del modelo.




Figura 2. Modelo lógico del DataMart Puntualidad de Vuelos.

PK: clave primaria. FK: clave foránea. NK: clave natural. DD: dimensión degenerada. Todas las relaciones son de uno a muchos.

5. MODELADO FÍSICO DEL DATAMART

5.1 Implementación en PostgreSQL

El modelo físico se implementó en PostgreSQL 16, en una base de datos llamada dw_vuelos. Se crearon las cinco tablas de dimensiones y la tabla de hechos con sus tipos de datos, claves, restricciones e índices. También se cargaron los datos fijos: el calendario de 2014 a 2016, las 24 horas del día y los motivos de cancelación. La Figura 3 muestra el modelo físico tal como quedó en la base de datos.

5.2 Tipos de datos y restricciones

La Tabla 8 resume los tipos de datos elegidos para las columnas de las tablas.

Tabla 8. Tipos de datos utilizados

Datos	Tipo de dato	Motivo
Claves sustitutas	INTEGER y BIGINT con IDENTITY	Se generan automáticamente.
Minutos, distancia e indicadores	SMALLINT	Son números pequeños y los indicadores se pueden sumar.
Fecha y hora programada	DATE y TIME	Permiten trabajar con fechas y horas.
Códigos y nombres	VARCHAR y CHAR	Texto de longitud limitada.

Las restricciones definidas son: clave primaria en todas las tablas, UNIQUE en los códigos IATA y en la combinación que identifica a cada vuelo, NOT NULL en las columnas obligatorias y reglas CHECK, por ejemplo, que la distancia sea mayor que cero o que un vuelo cancelado tenga un motivo de cancelación.

5.3 Relaciones e integridad referencial

Las relaciones entre la tabla de hechos y las dimensiones se crearon como claves foráneas: seis en total, dos de ellas hacia la dimensión aeropuerto. Para comprobar la integridad referencial se hicieron pruebas, y la base de datos rechazó correctamente un vuelo con una aerolínea que no existe, un vuelo cancelado sin motivo, un vuelo repetido, una distancia negativa y la eliminación de un aeropuerto que tiene vuelos registrados.

5.4 Preparación para las consultas y para el ETL

Para que las consultas sean rápidas se crearon índices sobre las claves foráneas, sobre la combinación de aerolínea y fecha, sobre las rutas (origen y destino) y un índice parcial para los vuelos cancelados. Para facilitar la carga con Apache Hop, las dimensiones de aerolínea y aeropuerto tienen un registro "Desconocido" con clave -1, que se usa cuando un código no se encuentra, y la clave del vuelo evita que se carguen vuelos repetidos si el proceso se ejecuta más de una vez.




Figura 3. Modelo físico del DataMart Puntualidad de Vuelos en PostgreSQL 16.

PK: clave primaria. FK: clave foránea. UK: restricción UNIQUE. NN: NOT NULL. IDENTITY: valor generado por la base de datos.